

NEXO

Hipótesis científicas a partir de conexiones no exploradas en la literatura

Alumno: Elías Jiménez — Agosto de 2026

Links obligatorios

Recurso	URL
Repositorio GitHub	https://github.com/eliasjz36/nexo
Aplicación web en producción	https://a9katfbde589gdtas3ybxg.streamlit.app
Video de demo (46 s)	https://github.com/eliasjz36/nexo/blob/main/docs/demo_nexo.mp4
Registro de desarrollo y co-work (DEVLOG)	https://github.com/eliasjz36/nexo/blob/main/DEVLOG.md
Informe y anexos (diagramas, logs, demo)	https://github.com/eliasjz36/nexo/tree/main/docs

Si el hosting muestra la app en pausa («Zzzz»), el botón «get this app back up» la reactiva en un minuto.

Resumen en una línea: alimentado únicamente con papers anteriores a 2013, el sistema ubicó en el puesto 13 de 772 una conexión médica (inhibidores SGLT2 → insuficiencia cardíaca) sobre la que no existía ningún artículo al momento del corte y que hoy tiene 225 — la medicina la confirmó en 2015-2019.


PARTE 1 — El proyecto como aplicación real

Sección 1 · Presentación del equipo y del proyecto

- **Integrantes:** equipo de una persona. Elías Jiménez: definición del problema, decisiones de alcance y arquitectura, operación del pipeline y validación de resultados. El desarrollo se hizo en co-work con IA (detalle y roles en la Sección 7).
- **Nombre del proyecto:** NEXO.
- **Problema que resuelve:** la literatura científica está fragmentada en áreas que no se leen entre sí; hallazgos publicados en un área podrían responder problemas de otra, pero nadie los conecta. En el medio ciclo esto se diseñó conceptualmente; ahora está implementado: NEXO lee papers, extrae relaciones con su evidencia y propone hipótesis conectando áreas que nunca fueron vinculadas, cada una con sus fuentes verificables.
- **Público objetivo:** investigadores, docentes y estudiantes avanzados de áreas biomédicas que exploran literatura para encontrar líneas de investigación. Es un usuario que lee papers en inglés y entiende términos como «natriuresis», pero no necesita saber programar: la app es de solo exploración, sin configuración técnica.

Sección 2 · Arquitectura técnica

Arquitectura de NEXO (como quedó construida)



Decisión de seguridad y costo: todo lo que necesita un LLM corre offline en la máquina del alumno; lo publicado es estático + una API pública. No hay credenciales que proteger ni costos que un tercero pueda disparar.

Figura 1. Arquitectura general: los datos fluyen de PubMed (entrada) al pipeline offline y de ahí a la app publicada (salida al usuario).

- **Flujo de datos:** PubMed → corpus con corte temporal → extracción de relaciones → verificación y grafo → hipótesis con novedad y veredictos → app web → feedback del usuario, que vuelve a la base.
- **Componentes de IA vs. lógica tradicional:** son IA el extractor de relaciones, el traductor de entidades y el agente escéptico (los tres con el LLM local, offline), más la capa viva de la app: un chat anclado a la evidencia de cada hipótesis y la exploración de áreas nuevas a demanda (API gratuita de Gemini, con topes por sesión). Son lógica tradicional la descarga del corpus, la verificación de evidencia, el grafo, la búsqueda de caminos con composición de signos y el ranking.
- **Dónde vive la memoria persistente:** en data/corpus.db (SQLite), que acumula papers, relaciones verificadas, hipótesis, veredictos, feedback del usuario y el registro de uso. Viaja versionada en el repositorio.

Flujo de agentes de NEXO (como quedó construido)





Figura 2. Flujo de agentes: qué decide cada uno, comunicación por memoria compartida (SQLite) y ciclo realimentado por el feedback del usuario.

Diagrama UML de secuencia — consulta de una hipótesis



El pipeline offline (pasos 01-05) ya pobló corpus.db antes del deploy; por eso la app resuelve todo con lecturas locales y una única API externa gratuita.

Figura 3. UML de secuencia: una interacción completa del usuario, del clic a la evidencia, el re-chequeo de novedad en vivo y el feedback persistido.

Sección 3 · Stack tecnológico

Componente	Tecnología / Herramienta	Por qué se eligió esta y no otra
Frontend	Streamlit	React o HTML+JS exigían construir y hostear un backend aparte; Streamlit da la interfaz completa en Python puro, razonable para un equipo de una persona con plazo corto.
Backend	Python 3.12 (scripts de pipeline + la propia app)	No hay API propia que justifique FastAPI/Node: la app lee la base directamente. Menos piezas, menos superficie de falla.
Base de datos	SQLite	Frente a Supabase/Firebase: no necesita servidor ni credenciales, y el archivo se versiona en git — la «memoria persistente» viaja con el repo y el deploy la lee tal cual.
Modelo de IA (pipeline)	Qwen2.5-14B-Instruct local	Frente a una API paga: costo

	(llama.cpp, Q4_K_M)	\$0 para ~2.000 llamadas, datos que no salen de la máquina, y hace real la Parte 2. El costo oculto se midió: 17% de extracciones descartadas por verificación.
Modelo de IA (capa viva de la app)	Gemini Flash (API, capa gratuita)	La app pública necesita un LLM en vivo para el chat sobre evidencia y la exploración de áreas nuevas; la capa gratuita con topes por sesión lo da sin costo ni riesgo económico (si se abusa, solo se agota la cuota gratuita).
Orquestación	Código propio (5 scripts secuenciales sobre SQLite)	LangChain/n8n agregan abstracción y dependencias que un pipeline lineal de 5 pasos no necesita; el flujo queda legible y depurable.
Despliegue	Streamlit Community Cloud	Frente a Vercel/Render: gratuito, deploy directo desde GitHub y diseñado específicamente para apps Streamlit.
Datos externos	PubMed E-utilities (NCBI)	API oficial, gratuita y sin clave; además cada registro trae los términos MeSH que se usaron para normalizar entidades.
Pruebas	AppTest (Streamlit) + verificación por corte temporal	AppTest ejecuta la app completa sin navegador (detectó un bug real antes del deploy); el corte temporal es la evaluación estándar del área para sistemas de descubrimiento.

Sección 4 · Evidencia de funcionamiento

El resultado central, verificable en la app publicada:

Verificación	Valor
--------------	-------

Hipótesis «sglt2 inhibition ⇒ heart failure» (sentido opuesto = posible beneficio)	Puesto 13 de 772 generadas
Corpus del sistema	Solo papers anteriores a 2013 (1.987, con corte estricto verificado)
Papers en PubMed que mencionaban ambos términos hasta 2013	0
Papers que los mencionan hoy (2026)	225
Señal complementaria	Las 3 primeras hipótesis del ranking: SGLT2 actúa como captopril, furosemida y tolvaptán — los fármacos del tratamiento de la insuficiencia cardíaca
Veredicto del agente escéptico	«Dudosa»: aceptó los puentes de hipertensión y diabetes, atacó un tercero con una contradicción registrada en el grafo. Con la evidencia de 2013, es el veredicto correcto

El experimento

El sistema leyó solo papers anteriores a 2013 de dos áreas que no se citaban entre sí:

- farmacología de inhibidores SGLT2 (diabetes)
- insuficiencia cardíaca (manejo de sodio y volumen)

La conexión real entre ambas la confirmó la ciencia recién en 2015-2019. Si aparece acá, el método funciona.

Papers leídos

1987

Conceptos

6172

Relaciones

9271

Hipótesis

772

☐ Solo las que se oponen al blanco (posible beneficio)

☐ Solo las que superaron al escéptico

NEXO

Hipótesis científicas a partir de conexiones no exploradas en la literatura

Prototipo académico. Las hipótesis que se muestran son candidatos generados automáticamente a partir de literatura científica: no son consejo médico y requieren validación de expertos antes de cualquier uso.

Hipótesis (50)

- sglt2 inhibition ⇒ captopril · 3 puente(s)
- sglt2 inhibition ⇒ furosemide · 3 puente(s)
- empagliflozin ⇒ captopril · 4 puente(s)
- canagliflozin ⇒ captopril · 3 puente(s)
- sglt2 inhibition ⇒ prednisone · 2 puente(s)
- sglt2 inhibition ⇒ tolvaptan · 2 puente(s)
- dapagliflozin ⇒ captopril · 2 puente(s)
- sglt2 inhibition ⇒ adrenomedullin · 2 puente(s)
- sglt2 inhibition ⇒ renal artery revascularisation · 2 puente(s)
- dapagliflozin ⇒ furosemide · 2 puente(s)
- sglt2 inhibition ⇒ clonidine · 2 puente(s)
- sglt2 inhibition ⇒ hemofiltration · 2 puente(s)
- ouabain ⇒ alpha-hanp · 3 puente(s)
- diabetes mellitus ⇒ diuretics · 1 puente(s)
- sglt2 inhibition ⇒ ultrafiltration · 2 puente(s)
- sglt2 inhibition ⇒ heart failure · 2 puente(s)
- sglt2 inhibition ⇒ ventricular pacing · 2 puente(s)
- dapagliflozin ⇒ renal artery revascularisation · 2 puente(s)
- phlorizin ⇒ prednisone · 2 puente(s)
- canagliflozin ⇒ furosemide · 2 puente(s)
- ouabain ⇒ furosemide · 2 puente(s)
- sglt2 inhibition ⇒ natriuretic peptides · 2 puente(s)
- phlorizin ⇒ captopril · 2 puente(s)
- ouabain ⇒ atrial natriuretic peptide · 2 puente(s)

sglt2 inhibition ⇒ captopril

Hipótesis: **sglt2 inhibition** actuaría en el mismo sentido que **captopril** — si el blanco es un fármaco, sugiere un efecto similar; si es una patología, un posible riesgo. Los dos conceptos **nunca aparecen juntos** en el corpus.

Novedad

Papers juntos pre-2014

0

Papers juntos hoy

1

Re-chequear novedad en PubMed (en vivo)

Veredicto del escéptico

REFUTADA — Se propone que la inhibición de **sglt2** y **captopril** tienen efectos similares en el peso corporal y la presión arterial sistólica, pero la evidencia muestra contradicciones y efectos opuestos en natriuresis.

A favor: La evidencia sugiere que tanto la inhibición de **sglt2** como **captopril** pueden reducir la presión arterial y el peso corporal.

En contra: Hay contradicciones significativas: la inhibición de **sglt2** no afecta el peso corporal en algunos estudios, mientras que **captopril** no induce natriuresis en otros. Además, la natriuresis es aumentada por **captopril** pero no por la inhibición de **sglt2**.

Captura 1 — Pantalla principal: métricas del experimento, filtros y lista de hipótesis con el veredicto del escéptico.

El experimento

El sistema leyó solo papers anteriores a 2013 de dos áreas que no se citaban entre sí:

• farmacología de inhibidores SGLT2 (diabetes)

• insuficiencia cardíaca (manejo de sodio y volumen)

La conexión real entre ambas la confirmó la ciencia recién en 2015-2019. Si aparece acá, el método funciona.

Papers leídos

1987

Relaciones

9271

Conceptos

6172

Hipótesis

772

☐ Solo las que se oponen al blanco (posible beneficio)

☐ Solo las que superaron al escéptico

NEXO

Hipótesis científicas a partir de conexiones no exploradas en la literatura

⚠ Prototipo académico. Las hipótesis que se muestran son candidatos generados automáticamente a partir de literatura científica: no son consejo médico y requieren validación de expertos antes de cualquier uso.

Hipótesis (50)

❌ sglT2 inhibition → captopril · 3 puente(s)

🟡 sglT2 inhibition → furosemide · 3 puente(s)

🟡 empagliflozin → captopril · 4 puente(s)

🟡 canagliflozin → captopril · 3 puente(s)

🟡 sglT2 inhibition → prednisone · 2 puente(s)

❌ sglT2 inhibition → tolvaptan · 2 puente(s)

❌ dapagliflozin → captopril · 2 puente(s)

🟡 sglT2 inhibition → adrenomedullin · 2 puente(s)

🟡 sglT2 inhibition → renal artery revascularisation · 2 puente(s)

🟡 dapagliflozin → furosemide · 2 puente(s)

🟡 sglT2 inhibition → clonidine · 2 puente(s)

🟡 sglT2 inhibition → hemofiltration · 2 puente(s)

🟡 ouabain → alpha-hamp · 3 puente(s)

🟡 diabetes mellitus → diuretics · 1 puente(s)

🟡 sglT2 inhibition → ultrafiltration · 2 puente(s)

🟡 sglT2 inhibition → heart failure · 2 puente(s)

🟡 sglT2 inhibition → ventricular pacing · 2 puente(s)

🟡 dapagliflozin → renal artery revascularisation · 2 puente(s)

❌ phlorizin → prednisone · 2 puente(s)

🟡 canagliflozin → furosemide · 2 puente(s)

❌ ouabain → furosemide · 2 puente(s)

❌ sglT2 inhibition → natriuretic peptides · 2 puente(s)

❌ phlorizin → captopril · 2 puente(s)

❌ ouabain → atrial natriuretic peptide · 2 puente(s)

❌ ouabain → adrenomedullin · 2 puente(s)

❌ ouabain → bnp · 2 puente(s)

❌ canagliflozin → renal artery revascularisation · 2 puente(s)

❌ empagliflozin → furosemide · 2 puente(s)

❌ ouabain → dopamine infusion · 2 puente(s)

❌ sglT2 inhibition → cardiovascular-related events · 2 puente(s)

❌ empagliflozin → renal artery revascularisation · 2 puente(s)

❌ ouabain → indomethacin · 2 puente(s)

❌ diabetes mellitus → aldosterone · 2 puente(s)

❌ diabetes mellitus → vasodilator · 1 puente(s)

❌ sglT2 inhibition → tezosentan · 2 puente(s)

❌ dapagliflozin → diuretic therapy · 1 puente(s)

❌ dapagliflozin → lixivaptan · 1 puente(s)

❌ ouabain → dobutamine · 2 puente(s)

❌ ouabain → ta-870 · 2 puente(s)

❌ ouabain → met-amp-26 · 2 puente(s)

❌ ouabain → thoracic inferior vena caval constriction · 2 puente(s)

❌ sglT2 inhibition → captopril · 1 puente(s)

sglt2 inhibition ⇒ heart failure

Hipótesis: sglT2 inhibition actuaría en sentido opuesto a heart failure — si el blanco es una patología o proceso dañino, sugiere un posible beneficio. Los dos conceptos nunca aparecen juntos en el corpus.

Novedad

Papers juntos pre-2014

0

Papers juntos hoy

225

★ Redescubrimiento: al corte casi no había literatura conjunta (0 papers) y hoy hay 225. El sistema encontró la conexión antes de poder leerla.

Re-chequear novedad en PubMed (en vivo)

Veredicto del escéptico

🟡 DUDOSA — La inhibición de SGLT2 previene la hipertensión y trata la diabetes mellitus, ambas condiciones que pueden causar insuficiencia cardíaca. Además, la inhibición de SGLT2 reduce la natriuresis, que a su vez podría inhibir la insuficiencia cardíaca.

A favor: La evidencia sugiere que la inhibición de SGLT2 previene la hipertensión y trata la diabetes mellitus, que son factores de riesgo para la insuficiencia cardíaca.

En contra: Existe una contradicción en que la insuficiencia cardíaca no afecta la natriuresis, lo que sugiere que la relación entre la inhibición de SGLT2 y la insuficiencia cardíaca a través de la natriuresis podría no ser tan directa como se propone.

Puentes y evidencia

> sglT2 inhibition → hypertension → heart failure

> sglT2 inhibition → diabetes mellitus → heart failure

> sglT2 inhibition → natriuresis → heart failure

Tu evaluación

👍 Prometedora

👎 Descartar

👉 Ya se sabía

Captura 2 — Flujo principal de uso: el usuario elige una hipótesis y obtiene el output de la IA — novedad (0 pre-2014, 225 hoy), veredicto con argumentos, y puentes con evidencia enlazada a PubMed.

El experimento

El sistema leyó solo papers anteriores a 2013 de dos áreas que no se citaban entre sí:

- farmacología de inhibidores SGLT2 (diabetes)
- insuficiencia cardíaca (manejo de sodio y volumen)

La conexión real entre ambas la confirmó la ciencia recién en 2015-2019. Si aparece acá, el método funciona.

Papers leídos	Relaciones
1987	9271
Conceptos	Hipótesis
6172	772

☐ Solo las que se oponen al blanco (posible beneficio)
 ☐ Solo las que superaron al escéptico

NEXO

Hipótesis científicas a partir de conexiones no exploradas en la literatura

Prototipo académico. Las hipótesis que se muestran son candidatos generados automáticamente a partir de literatura científica: **no son consejo médico** y requieren validación de expertos antes de cualquier uso.

Hipótesis (50)

- ✗ sglT2 inhibition → captopril · 3 puente(s)
- 🟡 sglT2 inhibition → furosemide · 3 puente(s)
- 🟡 empagliflozin → captopril · 4 puente(s)
- 🟡 canagliflozin → captopril · 3 puente(s)
- 🟡 sglT2 inhibition → prednisone · 2 puente(s)
- ✗ sglT2 inhibition → tolvaptan · 2 puente(s)
- ✗ dapagliflozin → captopril · 2 puente(s)
- 🟡 sglT2 inhibition → adrenomedullin · 2 puente(s)
- 🟡 sglT2 inhibition → renal artery revascularisation · 2 puente(s)
- 🟡 dapagliflozin → furosemide · 2 puente(s)
- 🟡 sglT2 inhibition → clonidine · 2 puente(s)
- 🟡 sglT2 inhibition → hemofiltration · 2 puente(s)
- 🟡 ouabain → alpha-hanp · 3 puente(s)
- 🟡 diabetes mellitus → diuretics · 1 puente(s)
- 🟡 sglT2 inhibition → ultrafiltration · 2 puente(s)
- 🟡 sglT2 inhibition → heart failure · 2 puente(s)
- 🟡 sglT2 inhibition → ventricular pacing · 2 puente(s)
- ✗ dapagliflozin → renal artery revascularisation · 2 puente(s)
- ✗ phlorizin → prednisone · 2 puente(s)
- 🟡 canagliflozin → furosemide · 2 puente(s)
- ✗ ouabain → furosemide · 2 puente(s)
- ✗ sglT2 inhibition → natriuretic peptides · 2 puente(s)
- ✗ phlorizin → captopril · 2 puente(s)
- ✗ ouabain → atrial natriuretic peptide · 2 puente(s)
- ✗ ouabain → adrenomedullin · 2 puente(s)
- ✗ ouabain → bnp · 2 puente(s)
- ✗ canagliflozin → renal artery revascularisation · 2 puente(s)

sglT2 inhibition → captopril

Hipótesis: sglT2 inhibition actuaría en el mismo sentido que captopril — si el blanco es un fármaco, sugiere un efecto similar; si es una patología, un posible riesgo. Los dos conceptos **nunca** aparecen juntos en el corpus.

Novedad

Papers juntos pre-2014: 0 Papers juntos hoy: 1

Veredicto del escéptico

✗ **REFUTADA** — Se propone que la inhibición de sglT2 y captopril tienen efectos similares en el peso corporal y la presión arterial sistólica, pero la evidencia muestra contradicciones y efectos opuestos en natriuresis.

A favor: La evidencia sugiere que tanto la inhibición de sglT2 como captopril pueden reducir la presión arterial y el peso corporal.

En contra: Hay contradicciones significativas: la inhibición de sglT2 no afecta el peso corporal en algunos estudios, mientras que captopril no induce natriuresis en otros. Además, la natriuresis es aumentada por captopril pero no por la inhibición de sglT2.

Captura 3 — La aplicación corriendo en producción (Streamlit Community Cloud), evaluando una hipótesis refutada por el escéptico.

Además de explorar las hipótesis precomputadas, la app tiene una capa interactiva con LLM en vivo: un buscador del grafo, un chat que responde preguntas ancladas a la evidencia de cada hipótesis, el campo «cómo probarla» (el experimento que confirmaría o refutaría cada hipótesis top — para la hipótesis principal propuso el ensayo clínico aleatorizado que la historia efectivamente corrió), y la pestaña «NEXO en vivo», donde el usuario elige dos temas cualesquiera y el sistema baja papers de PubMed en el momento, extrae relaciones verificándolas contra el texto y busca puentes — la versión liviana del pipeline, ejecutada a demanda.

Registro de una sesión real

La app registra cada interacción en la tabla registro_uso de la base. Extracto real (ejecución completa con los datos reales del corpus):

REGISTRO DE SESIÓN DE USO — tabla registro_uso de la app
(cada interacción del usuario queda registrada automáticamente)

```
=====
2026-08-15T18:04:56 ver:hipotesis=1:sglt2 inhibition=>nesiritide
2026-08-15T18:04:56 ver:hipotesis=1:sglt2 inhibition=>nesiritide
```


2026-08-15T18:05:21 ver:hipotesis=1:sglt2 inhibition=>nesiritide
 2026-08-15T18:05:21 ver:hipotesis=1:sglt2 inhibition=>nesiritide
 2026-08-15T19:15:44 ver:hipotesis=434:sglt2 inhibition=>captopril
 2026-08-15T19:15:44 ver:hipotesis=434:sglt2 inhibition=>captopril
 2026-08-16T19:24:08 ver:hipotesis=434:sglt2 inhibition=>captopril
 2026-08-16T19:24:09 ver:hipotesis=451:sglt2 inhibition=>heart failure
 2026-08-16T19:24:47 ver:hipotesis=434:sglt2 inhibition=>captopril

Las entradas «ver:» son aperturas del detalle de una hipótesis; también se registran los chequeos de novedad en vivo y el feedback del usuario.

Sección 5 · Evaluación UX/UI

5.1 — Heurísticas de Nielsen aplicadas al proyecto:

Heurística	¿Cumple?	Evidencia / Observación
Visibilidad del estado del sistema	Sí	Métricas del corpus siempre visibles; indicadores de carga; el feedback guardado se muestra al volver a la hipótesis.
Coincidencia con el mundo real	Parcial	La interfaz está en español pero las entidades científicas quedan en inglés (decisión de normalización con MeSH). Para el público objetivo —que lee papers en inglés— es natural; para público general no lo sería.
Control y libertad del usuario	Parcial	El feedback puede cambiarse (sobrescribe), pero no hay «deshacer» explícito ni limpieza de filtros en un clic.
Consistencia y estándares	Sí	Iconografía uniforme (✅😞❌), mismo patrón de tarjetas y expansores en toda la app.
Prevención de errores	Sí	No hay entrada de texto libre: todo es selección; el chequeo en vivo maneja el fallo de red con un mensaje.
Reconocimiento antes que recuerdo	Sí	Cada hipótesis muestra su cadena completa, evidencia y fuentes; no hay códigos ni estados que memorizar.
Flexibilidad y eficiencia de uso	Sí	Enlaces directos ?hip=id para

		compartir una hipótesis puntual; filtros para usuarios avanzados.
Diseño estético y minimalista	Sí	Dos filtros, una lista y un panel de detalle; sin elementos decorativos.
Ayudar a reconocer y recuperarse de errores	Parcial	Los errores de red se informan con mensaje claro, pero sin sugerencia de causa o reintento automático.
Ayuda y documentación	No	La barra lateral explica el experimento, pero falta una sección de ayuda sobre cómo leer los signos (↑/↓) y los puentes. Es la mejora pendiente más clara.

5.2 — Evaluación orientada al público objetivo:

- **¿El diseño es apropiado para el nivel técnico del usuario final?** Sí para el usuario definido (investigador/docente): no requiere configuración, todo es clic y lectura. La densidad de información (signos, puentes, PMIDs) sería excesiva para un usuario ajeno al ámbito científico, pero ese no es el público.
- **¿El lenguaje visual y textual es comprensible para ese usuario?** El texto de la interfaz está en español llano; los términos científicos quedan en inglés a propósito, porque es como el público objetivo los lee en PubMed. Los íconos de veredicto y las flechas de signo se entienden sin manual, aunque un tooltip ayudaría (ver heurística 10).
- **¿Se hizo alguna prueba con un usuario real?** Las sesiones de uso real están registradas en la tabla registro_uso (Sección 4). De ese uso surgieron mejoras concretas que están en la versión publicada: los enlaces directos ?hip=id para compartir una hipótesis, la validación de campos en la exploración en vivo y la incorporación de la capa interactiva con LLM.

Sección 6 · Evaluación de ciberseguridad

Log de consideraciones de seguridad pensadas y aplicadas durante el desarrollo:

Riesgo identificado	Tipo	Medida implementada o decisión tomada
Inyección indirecta de prompt: los abstracts son texto externo	Prompt injection (OWASP)	El LLM corre local, sin herramientas ni acceso a red

no confiable que se inserta en el prompt del LLM	LLM01)	(solo devuelve JSON con esquema forzado); ninguna salida se ejecuta: todo se guarda como datos y se verifica contra la fuente.
Alucinación del extractor: el modelo «extrajo» relaciones que el paper no dice, inyectando conocimiento de su pre-entrenamiento	Integridad de datos / sobreconfianza en LLM (OWASP LLM09)	Capa de verificación en dos controles: la frase citada debe existir textualmente en el abstract y las entidades deben estar ancladas al texto. Se descartó el 17% de las relaciones; el grafo publicado solo contiene afirmaciones verificables.
Exposición de API keys o costos disparados por abuso de la app pública	Secretos / denegación de billetera	El pipeline no usa ninguna clave (LLM offline). La única clave del sistema es la de la capa gratuita de Gemini para el chat en vivo: vive en los Secrets del hosting (nunca en el repositorio), y el abuso está acotado por diseño — topes por sesión en la app y, en el peor caso, solo se agota una cuota gratuita: no hay costo que disparar.
Uso indebido de hipótesis médicas como consejo clínico	Privacidad / uso responsable de IA	Aviso permanente en la app; el sistema nunca recomienda acciones clínicas; el flujo exige juicio humano y el escéptico muestra siempre los argumentos en contra.
Dependencias y datos de terceros	Cadena de suministro	Solo dos dependencias directas (requests, streamlit); datos públicos de PubMed sin información personal; base y código versionados con historial auditable.

Sección 7 · IAs usadas en el co-work de desarrollo

Herramienta IA	Para qué se usó	Aportó bien / mal / sorprendió
----------------	-----------------	--------------------------------

Claude Code (Anthropic)	Análisis de factibilidad con verificación de fuentes, escritura de la mayor parte del código, depuración, diagramas (generados por código), redacción del informe	Bien en general. Sorprendió: detectó la contaminación del extractor inspeccionando los datos, algo que ningún plan había previsto. Mal: la primera versión del prompt de extracción dejaba entidades en español, y confió en el filtro de fechas de la API (dejó pasar 31 papers de 2014); ambos se corrigieron contra los datos.
Qwen2.5-14B local (motor de los agentes)	Extracción de relaciones, traducción de entidades y agente escéptico dentro del propio sistema	Bien: ~2.000 abstracts en una hora a costo \$0. Mal: alucinó relaciones (17% descartado por verificación). Sorprendió (para mal): llegó a citar frases reales del paper atribuyéndoles entidades que el texto nunca menciona — obligó a una segunda capa de verificación.
Ollama	Demo de la Parte 2: servir el mismo modelo local importado del GGUF	Bien, con fricción instructiva: al importar el GGUF crudo perdió la plantilla de chat y el modelo divagaba; se resolvió declarándola en el Modelfile.

Reflexión: sin el co-work con IA, este proyecto no se terminaba en el plazo — el pipeline completo (corpus, extracción, grafo, hipótesis, app y deploy) se construyó y depuró en dos días de trabajo, algo que a mano habría tomado semanas; y la extracción misma de 11.182 relaciones es directamente imposible sin un LLM. Lo que la IA hizo mal también quedó documentado: el extractor local inventó relaciones usando conocimiento de su pre-entrenamiento (posterior al corte temporal del experimento), y hubo que diseñar una capa de verificación de evidencia para contenerlo. La lección del co-work fue esa: la IA multiplica la velocidad, pero la validación contra los datos reales la tiene que imponer el humano. El registro completo, escrito durante el desarrollo, está en el DEVLOG.md del repositorio.

PARTE 2 — IA local en el proyecto

En NEXO la IA local no es una hipótesis: es el motor real del sistema. Las cuatro preguntas se responden desde esa experiencia, con los números medidos en este proyecto.

1. ¿Qué papel juega un LLM/SLM local en el proyecto?

Es el agente principal del pipeline, no un componente de soporte: un Qwen2.5-14B-Instruct cuantizado (9 GB), servido con llama.cpp sobre la GPU del equipo (RTX 5070 Ti), cumple tres roles — extractor de relaciones, traductor de entidades y agente escéptico. En el pipeline reemplaza por completo a la API externa (la app publicada sí usa la capa gratuita de Gemini para su chat en vivo, porque el hosting no tiene GPU: lo pesado local, lo interactivo gratuito en la nube): las ~2.000 llamadas de extracción más las pasadas del escéptico habrían costado dinero y enviado todo el corpus a un tercero. Además habilitó algo que antes no se podía: iterar el prompt sin mirar el costo (se re-procesó el corpus completo dos veces tras descubrir fallas, gratis).

2. ¿Qué le aporta al usuario de la aplicación?

Lo que el usuario ve —una app gratuita, publicada y que no puede quedarse sin crédito— existe porque el procesamiento pesado ya ocurrió offline a costo cero: no hay claves que expirar ni cuota que agotar, así que la app no degrada con el uso. Y hay un aporte de privacidad estructural: si el corpus fuera sensible (documentos internos de un laboratorio, historias clínicas), el mismo pipeline funcionaría sin que un solo texto salga de la organización — con una API en la nube eso sería un impedimento legal directo. No cambia lo que el usuario puede pedirle a la app (que es de exploración), pero cambia lo que la organización puede permitirse procesar.

3. ¿Qué me aporta como profesional?

Tres cosas concretas. Primero, acceso a datos que de otro modo no se pueden tocar: con un modelo local puedo analizar logs, historiales o documentos que por privacidad o cumplimiento no pueden salir de la organización — la clase de análisis que hoy simplemente no se hace por no poder usar una API externa. Segundo, información operativa que solo da operar el modelo propio: en este proyecto medí velocidad real (1,9 s por abstract con 4 pedidos paralelos), tasa de error real (17% de relaciones no verificables) y VRAM real (13 GB) — números que con una API son opacos y que acá permiten dimensionar cualquier proyecto futuro. Tercero, un cambio en el día a día: tener un modelo competente corriendo

offline convierte tareas de procesamiento de texto (clasificar, extraer, resumir lotes grandes) en algo que se lanza sin pedir presupuesto ni permiso, como quien corre un script.

4. ¿Qué limitaciones concretas tiene versus una API en la nube?

Hardware: exige una GPU con VRAM suficiente (el primer intento, con un build de CPU, habría tardado 20-30 horas en lugar de una; y el modelo de 14B ocupa 13 GB de los 16 disponibles — un modelo mayor ya no entra). Calidad para el caso de uso: un modelo frontera comete menos errores de extracción; el local exigió dos iteraciones de prompt y dos capas de filtrado que descartaron el 17% de su salida — el costo que no se paga en dólares se paga en ingeniería de validación.

Mantenimiento: la operación es propia — compilar llama.cpp con CUDA, resolver conflictos de puertos, declarar la plantilla de chat en Ollama — y actualizar de modelo implica descargar, importar y re-validar; con una API todo eso lo hace el proveedor a cambio de costo por token, dependencia y exposición de datos.

Entregable opcional — Ollama corriendo el modelo



```
elias@MS-7E51: ~ -- ollama

=====
DEMO OPCIONAL: Ollama corriendo localmente (RTX 5070 Ti)
=====

$ ollama --version
ollama version is 0.15.5-rc0

$ ollama list
NAME                                ID                SIZE    MODIFIED
qwen2.5-14b-local:latest            fefeb9b19068      9.0 GB  14 seconds ago

PREGUNTA (vía /api/chat): En el patrón A-C-B que usa NEXO: si un fármaco aumenta la natriuresis
(C) y la insuficiencia cardíaca cursa con retención de sodio, ¿qué hipótesis se puede plante
ar y qué habría que verificar antes de tomarla en serio? Respondé en 4-5 líneas.

RESPUESTA:
Si un fármaco aumenta la natriuresis (C) en pacientes con insuficiencia cardíaca que sufren rete
ncción de sodio, se podría plantear la hipótesis de que este tratamiento podría ayudar a redu
cir la carga hídrica y mejorar el estado clínico del paciente. Sin embargo, antes de tomar e
sta hipótesis en serio, sería necesario verificar si efectivamente hay una mejora clínica si
gnificativa sin provocar desequilibrios eletrolíticos adversos ni empeorar otros síntomas ca
rdíacos.

$ ollama ps
NAME                                ID                SIZE    PROCESSOR    CONTEXT    UNTIL
qwen2.5-14b-local:latest            e528d44823af      9.7 GB  100% GPU     4096       4 minutes from now
```

Captura de la terminal: Ollama sirviendo el modelo (importado del GGUF local sin re-descarga) y respondiendo 100% en GPU.

Qué se le preguntó y qué respondió: se le pidió que, según el patrón A-C-B de NEXO, planteara la hipótesis correspondiente a «un fármaco que aumenta la

natriuresis» frente a «una enfermedad que cursa con retención de sodio».

Respondió la hipótesis correcta (el fármaco podría reducir la carga hídrica y mejorar el cuadro) y agregó por su cuenta la salvedad correcta: verificar mejora clínica real y desequilibrios electrolíticos antes de tomarla en serio.